

KÜNSTLICHE INTELLIGENZ UND GESELLSCHAFT

Vorlesung 2: Performance von Klassifizierungsalgorithmen

Jana Lasser

Forschungsgruppe
Complex Social & Computational Systems (CS)²

IDEa_lab

Das Interdisziplinäre Digitale
Labor der Universität Graz




Performance

- Die **Performance** (Leistungsfähigkeit) eines Klassifizierungsalgorithmus misst, wie gut er Beobachtungen x den Klassen y zuordnen kann.
- Die Performance eines Algorithmus zu kennen ist an drei Stellen wichtig:
 1. Um das **Training** in Richtung besserer Performance zu **steuern**.
 2. Um das **Training zu beenden**, wenn die Performance nicht mehr besser wird.
 3. Nach Ende des Trainings, um die **finale Performance** des Algorithmus einschätzen zu können.

Im Folgenden lernen wir verschiedene Wege, die Performance eines Algorithmus zu messen.

Beispiel: Klassifizierung von Brustkrebs



WAHRER WERT	VORHERGESAGTER WERT
ja	ja
nein	nein
ja	nein
ja	ja
ja	ja
nein	ja
nein	nein
ja	ja
nein	ja
nein	ja
ja	ja
nein	nein
ja	ja
nein	nein

Quelle Beispielbild Brustkrebs: [Wikimedia Commons](#), CC BY-SA 3.0.

Performance des Klassifikators

Naiver Ansatz: Rechne die Fehlerrate aus.

Fehlerrate: Anteil an Beobachtungen die falsch klassifiziert wurden.

Hier: 14 Beobachtungen, 4 Fehler = 28.6% Fehlerrate.
Bzw. $100\% - 28.6\% = 71.4\%$ **Genauigkeit** (accuracy).


Problem: der Klassifikator kann **zwei Arten** von Fehlern machen die so nicht unterscheidbar sind:

1. **Falsch positiv:** in einem Bild wird Krebs erkannt obwohl keiner da ist.
2. **Falsch negativ:** in einem Bild mit Krebs wird dieser nicht erkannt.

WAHRER WERT	VORHERGESAGTER WERT
ja	ja
nein	nein
ja	nein
ja	ja
ja	ja
nein	ja
nein	nein
ja	ja
nein	ja
nein	ja
ja	ja
nein	nein
ja	ja
nein	nein

Fehlermatrix

Eine 2x2 Tabelle, die den wahren und vorhergesagten Wert von Beobachtungen zusammenfasst.



● Brustkrebs


○ kein Brustkrebs

○ Vorhersage
Brustkrebs

		WAHRER WERT		GESAMT
		JA	NEIN	
VORHERGESAGTER WERT	JA	echt positiv	falsch positiv	
	NEIN	falsch negativ	echt negativ	
GESAMT				

Fehlermatrix

Eine 2x2 Tabelle, die den wahren und vorhergesagten Wert von Beobachtungen zusammenfasst.



● Brustkrebs

○ kein Brustkrebs

○ Vorhersage
Brustkrebs

		WAHRER WERT		GESAMT
		JA	NEIN	
VORHERGESAGTER WERT	JA	6	3	9
	NEIN	1	4	5
GESAMT		7	7	14


WAHRER WERT	VORHERGESAGTER WERT
ja	ja
nein	nein
ja	nein
ja	ja
ja	ja
nein	ja
nein	nein
ja	ja
nein	ja
nein	ja
ja	ja
nein	nein
ja	ja
nein	nein

Fehlermatrix

Eine 2x2 Tabelle, die den wahren und vorhergesagten Wert von Beobachtungen zusammenfasst.

Berechne die
falsch positiv Rate: $1 / (1 + 6) = 14.3\%$

		WAHRER WERT		GESAMT
		JA	NEIN	
VORHERGESAGTER WERT	JA	6	3	9
	NEIN	1	4	5
GESAMT		7	7	14



Fehlermatrix


Eine 2x2 Tabelle, die den wahren und vorhergesagten Wert von Beobachtungen zusammenfasst.

Berechne die

falsch positiv Rate: $1 / (1 + 6) = 14.3\%$

falsch negativ Rate: $3 / (3 + 4) = 42.9\%$

		WAHRER WERT		GESAMT
		JA	NEIN	
VORHERGESAGTER WERT	JA	6	3	9
	NEIN	1	4	5
GESAMT		7	7	14



Fehlermatrix

Eine 2x2 Tabelle, die den wahren und vorhergesagten Wert von Beobachtungen zusammenfasst.

Berechne die

falsch positiv Rate: $1 / (1 + 6) = 14.3\%$

falsch negativ Rate: $3 / (3 + 4) = 42.9\%$

Es gibt eine deutliche Imbalance zwischen falsch positiven und falsch negativen Fehlern! Welcher Fehler ist wichtiger?

**Ethische Aspekte
der KI**

		WAHRER WERT		GESAMT
		JA	NEIN	
VORHERGESAGTER WERT	JA	6	3	9
	NEIN	1	4	5
GESAMT		7	7	14

Häufigkeit von Klassen


Beispiel: *Brustkrebs Screening-Programm. Eine von 100 Frauen hat tatsächlich Brustkrebs. Das heißt: negative Fälle sind 1:100 überrepräsentiert.*

- Ein Klassifikator der immer "kein Brustkrebs" vorhersagt, hat eine Genauigkeit von 99%!
- Er hat allerdings eine falsch positiv Rate von 0% und eine falsch negativ Rate von 100%.
- Wird nur die Genauigkeit angegeben, sieht der Klassifikator sehr gut aus. In der Realität ist er für den Anwendungsfall aber absolut unbrauchbar.

Verschiedene Indikatoren für Performance


Sensitivität
(sensitivity, recall) $\frac{r_p}{r_p + f_n}$

Die Wahrscheinlichkeit, mit der eine positive Beobachtung korrekt als positiv klassifiziert wird.




Spezifizität
(specificity) $\frac{r_n}{r_n + f_p}$

Die Wahrscheinlichkeit, mit der eine negative Beobachtung korrekt als negativ klassifiziert wird.



positiver Vorhersagewert
(precision) $\frac{r_p}{r_p + f_p}$

Der Anteil der korrekt als positiv klassifizierten Beobachtungen an der Gesamtheit der als positiv klassifizierten Beobachtungen.



		WAHR	
		JA	NEIN
VORH.	JA	r_p	f_p
	NEIN	f_n	r_n

Kombinierte Maße

Das F -Maß (auch F_1 -Maß) ist der harmonische Mittelwert von pos. Vorhersagewert und Sensitivität, wobei beide Werte gleich gewichtet sind.

$$F_1 = 2 \cdot \frac{\text{pos. Vorhersagewert} \cdot \text{Sensitivität}}{\text{pos. Vorhersagewert} + \text{Sensitivität}}$$

Allgemein: Das F_α -Maß mit unterschiedlichen Gewichten.

$$F_\alpha = (1 + \alpha^2) \cdot \frac{\text{pos. Vorhersagewert} \cdot \text{Sensitivität}}{\alpha^2 \cdot \text{pos. Vorhersagewert} + \text{Sensitivität}}$$

F_2 gewichtet den pos. Vorhersagewert viermal so hoch wie die Sensitivität.

$F_{0.5}$ gewichtet die Sensitivität viermal so hoch wie den pos. Vorhersagewert.

Wann welchen Performanceindikator verwenden?

- **Genauigkeit** (accuracy): Wenn **Klassen gleich häufig** sind und falsch positive und falsch negative Fehler gleich schlimm sind.
- **Sensitivität** (sensitivity, recall): Wenn Klassen nicht gleich häufig und **falsch negative Fehler** besonders schlimm sind.
- **Spezifizität** (specificity) bzw. **pos. Vorhersagewert** (precision): Wenn Klassen nicht gleich häufig und **falsch positive Fehler** besonders schlimm sind.
- F_1 : wenn **Klassen nicht gleich häufig** und sowohl falsch positive Fehler als auch falsch negative Fehler schlimm sind.

Zusammenfassung

- Die **Performance** eines Klassifikators zu kennen ist wichtig, um das **Training zu steuern** und die **Effektivität** des Klassifikators einzuschätzen.
- Klassifikatoren machen **unterschiedliche Fehler**:
 - **Falsch positiv**: eine negative Beobachtung wird als positiv klassifiziert.
 - **Falsch negativ**: eine positive Beobachtung wird als negativ klassifiziert.
- Je nach Wichtigkeit der verschiedenen Fehler kommen **unterschiedliche Indikatoren** für Performance zum Einsatz:
 - Genauigkeit
 - Sensitivität, Spezifität, positiver Vorhersagewert
 - F_1 bzw. F_α Maß