

WiSe 2024/25

KÜNSTLICHE INTELLIGENZ UND GESELLSCHAFT

Vorlesung 3: Bias und Varianz

Jana Lasser

Forschungsgruppe
Complex Social & Computational Systems (CS)²

IDEa_lab

Das Interdisziplinäre Digitale
Labor der Universität Graz




Fehlerquellen

- Im Abschnitt über Performance Indikatoren haben wir gesehen, dass es **unterschiedliche Typen** von Fehlern gibt.
- Es gibt auch **unterschiedliche Gründe**, warum machine learning Modelle Fehler machen.
- Diese Gründe können sowohl in den **Trainingsdaten** als auch im **Trainingsprozess** liegen.

Im Folgenden sehen wir uns die Gründe näher an.

Bias (Verzerrung)

- Bias eines Modelles: Unterschied zwischen seiner **durchschnittlichen Vorhersage** und dem wahren Wert.
- **Beispiel**
 - Wir trainieren ein Modell darauf, Katzen und Hunde auf Bildern zu erkennen.
 - Katzen kommen im Trainingsdatensatz viel häufiger vor als Hunde.
 - Als Resultat sagt das Modell viel wahrscheinlicher "Katze" voraus, als "Hund".
 - Das Modell hat einen Katzenbias!



Quelle Katzenbild: [Wikimedia Commons CC BY-SA](#).

Quelle Hundebild: [Wikimedia Commons, CC BY](#).

**Ethische Aspekte
der KI**

**Rechtliche
Aspekte der KI**

Varianz

- Varianz eines Modelles: Streuung von Vorhersagen für ähnliche Eingabewerte.
- **Beispiel**
 - Wir trainieren ein Modell darauf, Ponys und Pferde auf Bildern zu erkennen.
 - In den Trainingsdaten kommen nur braune Pferde und weiße Ponys vor.
 - Das Modell lernt, braun → Pferd sowie weiß → Pony zu assoziieren.
 - Die Performance auf neuen Daten mit weißen Pferden und braunen Ponys ist extrem schlecht.
- Zu hoher Varianz kann es auch kommen, wenn das **Modell zu komplex** ist (also viele Parameter hat) und damit zu viele Details der Trainingsdaten lernt.

Trainingsdaten



unbekannte Daten



Quelle Pony weiß: [Wikimedia Commons](#), CC BY-SA.

Quelle Pony Braun: [Wikimedia Commons](#), CC BY-SA.


Quelle Pferd weiß: [Wikimedia commons](#), CC BY.

Bias und Varianz


- Im Kontext von maschinellem Lernen wird Bias auch **underfitting** genannt:
- → der Algorithmus lernt die Verbindungen zwischen Attributen und Ausgaben nicht.
- Varianz wird auch **overfitting** genannt:
- → der Algorithmus modelliert falsche Korrelationen oder Rauschen anstatt der gewünschten Verbindungen zwischen Attributen und Ausgaben.

Quelle Illustration: Angepasst von Scott Fortmann-Roe [Graphical illustration of bias and variance](#).

niedriger Bias





niedrige Varianz



hohe Varianz


hoher Bias



Beispiel: Vorhersage einer Wahl

Vorhersage für Florida 2020

tatsächliches Ergebnis



Kandidaten	Gewonnen	
	Stimmen %	Stimmen absolut
 Donald Trump Republican Party	51,2 %	5.668.731
 Joe Biden Democratic Party	47,9 %	5.297.045


Mögliche Fehlerquellen

- **Bias:** Attribute der Befragten wie Bildung oder Anschluss an ein Festnetztelefon wurden nicht berücksichtigt → die Vorhersage unterschätzt systematisch die Anzahl von Trump-Wähler:innen.
- **Varianz:** Nicht genug befragte Personen, das Modell lernt die Attribute einzelner Personen → die Vorhersage wird stark von der zufälligen Auswahl der Befragten beeinflusst.

Beispiel: Vorhersage von Lungenentzündung

- **Ziel:** Entdecken von Entzündungen auf Röntgenbildern von Lungen.
- **Trainingsdatensatz:** Röntgenbilder aus drei Spitälern.
- Häufigkeit von Lungenentzündungen:
 - Spital 1: 1.2%
 - Spital 2: 34.2%
 - Spital 3: 1.0%.
- Das machine learning Modell bekommt sowohl die Bilder als auch die **Metadaten** (welches Spital, welches Gerät, Uhrzeit etc.) zum Lernen.

Siehe auch [Zech et al., PLoS Medicine \(2018\)](#).



Röntgenbilder von Lungen. Quelle: Wikimedia Commons, public domain.

Mögliche Probleme?

*Das Modell lernt **aus welchem Spital** die Bilder kommen und nicht die Charakteristika einer Lungenentzündung → **Bias**.*

Quellen von Bias


- **Auswahl von Daten:** Datensätze sollten die zugrundeliegende Population abbilden.
Beispiel: ein Algorithmus zur Gesichtserkennung der auf Bildern von mehrheitlich weißen Männern trainiert ist und schwarze Frauen sehr schlecht erkennt.
- **Vorurteile und Korrelationen:** Attribute können ungewünschte Korrelationen enthalten die Vorurteile widerspiegeln.
Beispiel: ein recruiting Algorithmus der die Postleitzahl mit einbezieht und dadurch Migranten diskriminiert.
- **Fehlende Informationen:** nicht im Datensatz enthaltene Attribute können sehr wichtig für das Resultat sein.
Beispiel: Vorhersage der Kauffreudigkeit von Kunden. Kunden aus Land X geben doppelt so viel Geld aus wie Kunden aus Land Y aber das Herkunftsland wird nicht erhoben und ist nicht für die Vorhersage verfügbar.
- **Andere Datenquelle:** wenn die Datenquelle für die Trainingsdaten eine andere ist als für die Daten im Anwendungsfall.
Beispiel: die Trainingsdaten für einen Bilderkennungsalgorithmus werden mit einer Nikon Kamera aufgenommen, die Daten für die Anwendung kommen alle von Canon Kameras.

Korrekte Einschätzung der Varianz

*Beim überwachten Lernen tendieren Algorithmen dazu, ihre Trainingsdaten "auswendig" zu lernen.
→ der Vorhersagefehler auf den Trainingsdaten ist kein gutes Maß für die Varianz!*

Training-Test Ansatz

1. Teile die Daten mit bekannten Klassen in zwei Teile, den **Trainingsdatensatz** (z.B. 80% der Daten) und den **Testdatensatz** (z.B. 20% der Daten).
2. Trainiere das Modell nur mit dem Trainingsdatensatz.
3. Sage mit dem trainierten Modell die Klassen im Testdatensatz voraus.
4. Vergleiche die vorhergesagten mit den wahren Klassen.
5. (Optional) Teile einen dritten Teil ab (**Validierungsdaten**) um das Modell während der Entwicklung zu evaulieren.



Zusammenfassung

- Fehler von machine learning Modellen haben zwei Gründe:
 - **Bias** (Verzerrung): eine systematische Abweichung der Modellvorhersagen vom wahren Wert.
 - **Varianz**: eine starke Streuung von Vorhersagen für ähnliche Eingabewerte.
- Gründe für Bias und Varianz können sowohl in den Trainingsdaten als auch im Trainingsprozess liegen.
- Systematische Identifikation von Verzerrungen in Trainingsdaten hilft, Modellbias zu verringern.
- Aufteilen der Daten in Training- und Testdatensatz hilft overfitting zu verhindern und die Varianz korrekt einzuschätzen.