

WiSe 2024/25

# KÜNSTLICHE INTELLIGENZ UND GESELLSCHAFT

## Vorlesung 2: Datentypen & Datenprobleme

**Jana Lasser**

Forschungsgruppe  
Complex Social & Computational Systems (CS)<sup>2</sup>

**IDEa\_lab**

Das Interdisziplinäre Digitale  
Labor der Universität Graz



# Daten, Daten, Daten

- In allen besprochenen Beispielen hatten wir es auf die ein- oder andere Weise mit Daten zu tun: Zahlen, Bilder, Text, ...
- Viele der Fallstricke beim Einsatz von KI haben mit den Daten zu tun.  
"Garbage in, garbage out".

*Im Folgenden beschäftigen wir uns intensiv mit Daten. Welche Daten gibt es? Wie können wir sie beschreiben? Und wie müssen wir mit ihnen umgehen um Fehler zu vermeiden?*

# Zahlen

# Unterschiedliche Arten von Zahlen

- Zahlen kommen in zwei Sorten:
  - **Diskret:** Ganzzahlen (Integer). Beispiele: Anzahl Personen in einem Raum, Tage bis Weihnachten, Anrufe bei der Telefonhotline.

*Beispiel:  
Informationen zu  
verschiedenen  
Weinen.*

| ALTER | RATING | ZUCKERGEH. |
|-------|--------|------------|
| 12    | 1      | 1.3        |
| 13    | 1      | 1.7        |
| 1     | 2      | 1.5        |
| 8     | 3      | 3.3        |
| 3     | 4      | 3.0        |
| 2     | 3      | 2.1        |

# Unterschiedliche Arten von Zahlen

- Zahlen kommen in zwei Sorten:
  - **Diskret:** Ganzzahlen (Integer). Beispiele: Anzahl Personen in einem Raum, Tage bis Weihnachten, Anrufe bei der Telefonhotline.
  - **Kontinuierlich:** Kommazahlen (floats). Beispiele: Gewicht einer Person, Distanz nach Paris, Anteil von Frauen in einer Vorlesung, Temperatur.

*Beispiel:  
Informationen zu  
verschiedenen  
Weinen.*

| ALTER | RATING | ZUCKERGEH. |
|-------|--------|------------|
| 12    | 1      | 1.3        |
| 13    | 1      | 1.7        |
| 1     | 2      | 1.5        |
| 8     | 3      | 3.3        |
| 3     | 4      | 3.0        |
| 2     | 3      | 2.1        |

# Tabellen

*Oft auch "data frames", "data tables" oder "Matrix" genannt.*

## Spalte

alle Werte eines Attributs

| ALTER | RATING | ZUCKERGEH. |
|-------|--------|------------|
| 12    | 1      | 1.3        |
| 13    | 1      | 1.7        |
| 1     | 2      | 1.5        |
| 8     | 3      | 3.3        |
| 3     | 4      | 3.0        |
| 2     | 3      | 2.1        |

## Zeile

alle Werte

einer

Beobachtung

# Probleme mit Zahlen

- **Fehlende Werte** können Leerstellen in den Daten sein, aber auch mit **Platzhaltern** wie "-1" oder "NA" markiert sein.

*Beispiel:  
Informationen zu  
verschiedenen  
Weinen.*

| ALTER | RATING | ZUCKERGEH. |
|-------|--------|------------|
| -1    | 1      | 1.3        |
| 13    | 1      | NA         |
| 1     |        | 1.5        |
| 8     |        | 3.3        |
| 3     | 4      | 3.0        |
| -1    | 3      | NA         |

# Probleme mit Zahlen

- **Fehlende Werte** können Leerstellen in den Daten sein, aber auch mit **Platzhaltern** wie "-1" oder "NA" markiert sein.
- **Ausreißer** (outlier): Werte die sich weit außerhalb des erwarteten Wertebereichs befinden.

*Beispiel:  
Informationen zu  
verschiedenen  
Weinen.*

| ALTER | RATING | ZUCKERGEH. |
|-------|--------|------------|
| 12    | 1      | 0.001      |
| 13    | 1      | 1.7        |
| 1     | 2      | 1.5        |
| 8     | 3      | 3.3        |
| 1998  | 4      | 3.0        |
| 2     | 3      | 2.1        |



# Probleme mit Zahlen

- **Fehlende Werte** können Leerstellen in den Daten sein, aber auch mit **Platzhaltern** wie "-1" oder "NA" markiert sein.
- **Ausreißer** (outlier): Werte die sich weit außerhalb des erwarteten Wertebereichs befinden.
- **Verbotene Werte**: Werte die sich außerhalb des erlaubten Wertebereichs befinden.

*Beispiel:  
Informationen zu  
verschiedenen  
Weinen.*

| ALTER | RATING | ZUCKERGEH. |
|-------|--------|------------|
| 12    | 1      | 1.3        |
| 13    | 1      | 1.7        |
| 1     | 2      | 1.5        |
| -10   | 3      | 3.3        |
| 3     | 4      | 3          |
| 2     | 3.3    | 2.1        |

# Probleme mit Zahlen finden

- **Annahmen über Zahlen überprüfen**
  - Welche Zahlen sind erlaubt?
  - Welche Wertebereiche sind erwartet?
  - Wie sind fehlende Werte codiert?
- **Deskriptive Statistik**
  - **Minimum:** die kleinste Zahl
  - **Maximum:** die größte Zahl
  - **Modus:** die häufigste Zahl
  - **Median:** welche Zahl ist genau in der Mitte wenn wir alle Zahlen von kleinster zu größter Zahl ordnen? Beispiel: [1, 1, 3, 5, 6, 6, 13]
  - **Mittelwert:** summiere alle Zahlen auf und teile sie durch die Anzahl der Zahlen

# Probleme mit Zahlen beheben

- **Fehlende Werte**

- Spalten oder Zeilen mit fehlenden Werten entfernen.
- Imputation: fehlende Werte mit Mittelwert, Median oder Modus ersetzen.

- **Ausreißer**

- Herausfinden, woher die Werte kommen.
- Durch Minimum / Maximum oder fehlenden Wert ersetzen.

- **Verbotene Werte**

- Herausfinden, woher die Werte kommen.
- Durch fehlende Werte ersetzen bzw. imputieren.

# Klassen / Kategorien

# Unterschiedliche Arten von Klassen

- **Kategorie:** Kann mehr als zwei Werte haben. Beispiele: Farbe, Geschlecht, Wohnort, Ethnie

*Beispiel:  
Informationen zu  
verschiedenen  
Weinen.*

| FARBE | VERFÜGBAR | RATING |
|-------|-----------|--------|
| rot   | ja        | 1      |
| weiß  | ja        | 1      |
| weiß  | nein      | 2      |
| rot   | nein      | 3      |
| weiß  | ja        | 4      |
| rot   | nein      | 3      |

# Unterschiedliche Arten von Klassen

- **Kategorie:** Kann mehr als zwei Werte haben. Beispiele: Farbe, Geschlecht, Wohnort, Ethnie, Qualität.

*Beispiel:  
Informationen zu  
verschiedenen  
Weinen.*

| FARBE | VERFÜGBAR | RATING |
|-------|-----------|--------|
| rot   | ja        | 1      |
| weiß  | ja        | 1      |
| weiß  | nein      | 2      |
| rot   | nein      | 3      |
| weiß  | ja        | 4      |
| rot   | nein      | 3      |

# Unterschiedliche Arten von Klassen

- **Kategorie:** Kann mehr als zwei Werte haben. Beispiele: Farbe, Geschlecht, Wohnort, Ethnie, Qualität.
- **Wahrheitswert:** "ja" oder "nein", oft auch "1" oder "0".

*Beispiel:  
Informationen zu  
verschiedenen  
Weinen.*

| FARBE | VERFÜGBAR | RATING |
|-------|-----------|--------|
| rot   | ja        | 1      |
| weiß  | ja        | 1      |
| weiß  | nein      | 2      |
| rot   | nein      | 3      |
| weiß  | ja        | 4      |
| rot   | nein      | 3      |

# Wie "rechnen" wir mit Klassen?

- Wahrheitswerte (binäre Attribute): in "0" und "1" übersetzen.

*Beispiel:  
Informationen zu  
verschiedenen  
Weinen.*

| VERFÜGBAR | FARBE |
|-----------|-------|
| 1         | rot   |
| 1         | weiß  |
| 0         | weiß  |
| 0         | rot   |
| 1         | weiß  |
| 0         | rot   |



# Wie "rechnen" wir mit Klassen?

- Wahrheitswerte (binäre Attribute): in "0" und "1" übersetzen.
- Kategorien mit zwei möglichen Werten: in Wahrheitswerte übersetzen.

*Beispiel:  
Informationen zu  
verschiedenen  
Weinen.*

| VERFÜGBAR | ROT |
|-----------|-----|
| 1         | 1   |
| 1         | 0   |
| 0         | 0   |
| 0         | 1   |
| 1         | 0   |
| 0         | 1   |

# Wie "rechnen" wir mit Klassen?

- Wahrheitswerte (binäre Attribute): in "0" und "1" übersetzen.
- Kategorien mit zwei möglichen Werten: in Wahrheitswerte übersetzen.
- Kategorien mit mehr als zwei möglichen Werten

*Beispiel:  
Informationen zu  
verschiedenen  
Weinen.*

| VERFÜGBAR | FARBE |
|-----------|-------|
| 1         | rot   |
| 1         | weiß  |
| 0         | weiß  |
| 0         | rot   |
| 1         | weiß  |
| 0         | rosé  |

# Wie "rechnen" wir mit Klassen?

- **Wahrheitswerte** (binäre Attribute): in "0" und "1" übersetzen.
- **Kategorien mit zwei möglichen Werten**: in Wahrheitswerte übersetzen.
- **Kategorien mit mehr als zwei möglichen Werten**: in mehrere Spalten auftrennen ("one-hot encoding").

*Beispiel:  
Informationen zu  
verschiedenen  
Weinen.*

| VERFÜGBAR | ROT | WEIß | ROSÉ |
|-----------|-----|------|------|
| 1         | 1   | 0    | 0    |
| 1         | 0   | 1    | 0    |
| 0         | 0   | 1    | 0    |
| 0         | 1   | 0    | 0    |
| 1         | 0   | 1    | 0    |
| 0         | 0   | 0    | 1    |

# Bilder







# Bilder bestehen aus Pixeln

Pixel (Bildpunkte) können wir in Zahlen umwandeln. Bilder haben schon Zeilen und Spalten. Eigentlich sind Bilder schon Tabellen.

|       | (0,1) | (0,2) | (0,3) | (0,4) | (0,5) | (0,6) | (0,7) | (0,8) |
|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| (0,0) | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     |
| (1,0) | 0     | 0     | 0     | 0     | 1     | 1     | 0     | 0     |
| (2,0) | 0     | 0     | 0     | 1     | 1     | 1     | 0     | 0     |
| (3,0) | 0     | 0     | 1     | 1     | 1     | 1     | 0     | 0     |
| (4,0) | 0     | 1     | 1     | 0     | 1     | 1     | 0     | 0     |
| (5,0) | 0     | 1     | 0     | 0     | 1     | 1     | 0     | 0     |
| (6,0) | 0     | 0     | 0     | 0     | 1     | 1     | 0     | 0     |
| (7,0) | 0     | 0     | 0     | 0     | 1     | 1     | 0     | 0     |
| (8,0) | 0     | 0     | 0     | 0     | 1     | 1     | 0     | 0     |
| (9,0) | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     |

| (0,1) | (0,2) | (0,3) | (0,4) | (0,5) | (0,6) | (0,7) | (0,8) |
|-------|-------|-------|-------|-------|-------|-------|-------|
| 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     |
| 0     | 0     | 0     | 0     | 1     | 1     | 0     | 0     |
| 0     | 0     | 0     | 1     | 1     | 1     | 0     | 0     |
| 0     | 0     | 1     | 1     | 1     | 1     | 0     | 0     |
| 0     | 1     | 1     | 0     | 1     | 1     | 0     | 0     |
| 0     | 1     | 0     | 0     | 1     | 1     | 0     | 0     |
| 0     | 0     | 0     | 0     | 1     | 1     | 0     | 0     |
| 0     | 0     | 0     | 0     | 1     | 1     | 0     | 0     |
| 0     | 0     | 0     | 0     | 1     | 1     | 0     | 0     |
| 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     |

# Bilder mit Farben



Text

# Text als Zahlen darstellen

Ich gehe mit  
dem Hund  
raus.

|       | Ich | gehe | mit | dem | Hund | raus |
|-------|-----|------|-----|-----|------|------|
| ich   | 1   | 0    | 0   | 0   | 0    | 0    |
| gehe  | 0   | 1    | 0   | 0   | 0    | 0    |
| mit   | 0   | 0    | 1   | 0   | 0    | 0    |
| dem   | 0   | 0    | 0   | 1   | 0    | 0    |
| Hund  | 0   | 0    | 0   | 0   | 1    | 0    |
| raus  | 0   | 0    | 0   | 0   | 0    | 1    |
| Katze | 0   | 0    | 0   | 0   | 0    | 0    |
| Haus  | 0   | 0    | 0   | 0   | 0    | 0    |
|       | ... | ...  | ... | ... | ...  | ...  |
| du    | 0   | 0    | 0   | 0   | 0    | 0    |


- Die Deutsche Standardsprache hat etwa 75.000 Wörter.
- Diese Idee führt schnell zu riesigen Tabellen.
- Mehr dazu in Vorlesung 4!



# Weitere Datentypen

# Zeitreihen


*Einzelne Zahlen die in einem regelmäßigen Zeitintervall aufgezeichnet werden.*



Temperaturverlauf seit 1850. Quelle: [Wikipedia](#), CC BY-SA 3.0

# Schall

*Viele Zahlen (Frequenzen) die in einem regelmäßigen Zeitintervall aufgezeichnet werden.*



Spektrogramm des Lieds "Oh No Girl". Quelle: [Wikipedia](#), CC BY-SA 3.0

# Zusammenfassung

- Um Daten für maschinelles Lernen nutzbar zu machen, müssen wir sie in **Zahlen in Tabellen** verwandeln.
- Es gibt unterschiedliche **Datentypen**, die sich alle auf die ein oder andere Art tabellarisch darstellen lassen.
  - Zahlen: diskret und kontinuierlich
  - Klassen: Wahrheitswerte (binäre Attribute) und Kategorien
  - Bilder: schwarz-weiß und farbig
  - Text
  - Zeitserien
- Um **Datenprobleme** zu entdecken und beheben ist es hilfreich, sich **deskriptive** Statistiken anzusehen (Minimum, Maximum, Modus, Median, Mittelwert).