

WiSe 2024/25

KÜNSTLICHE INTELLIGENZ UND GESELLSCHAFT

Vorlesung 2: Zusammenfassung Überwachtes Lernen

Jana Lasser

Forschungsgruppe
Complex Social & Computational Systems (CS)²

IDEa_lab

Das Interdisziplinäre Digitale
Labor der Universität Graz



Vorhersage von Krankheiten bei Kühen

- **Ziel:** Vorhersage von Krankheiten bei Kühen basierend auf möglichst diversen Daten.
- **Herausforderung:** Integration von sehr unterschiedlichen Daten.
- **Resultat:** mäßige (Ketose, $F_1 = 0.52$) bis gute (Stillbrunst, $F_1 = 0.74$) Performance.





Illustration der Integration verschiedener, über die Zeitachse verteilter Datenquellen.

Siehe auch [Lasser et al., J. Animal. Sci. \(2021\)](#).

Identifikation von Gegenredestrategien

- **Ziel:** Die Effektivität verschiedener Gegenredestrategien gegen Hassrede messen.
- **Herausforderung:** sehr schwer fassbare Klassen wie z.B. Sarkasmus.
- **Resultat:** Klassifikation ist gut genug um im Mittel über den sehr großen Datensatz (1.3 mio Tweets) einen Trend zu sehen.



Reconquista
Germanica



DER SPIEGEL DIE ZEIT
tagesschau¹

VS.

Reconquista
Internet



Performance des Klassifikators für Gegenredestrategien. Siehe auch [Lasser & Herderich et al., arXiv \(2024\)](#).

Klassifikation sexueller Orientierung

- **Ziel:** Klassifikation der sexuellen Orientierung von Bildern von einer Dating Site.
- **Resultat:** Der Klassifikator liefert gute Performance. Die Autoren interpretieren das als Evidenz dafür, dass sich sexuelle Orientierung in Gesichtern ablesen lässt.
- **Kritik:** Es ist deutlich wahrscheinlicher, dass der Algorithmus die Orientierung und Behaarung des Gesichts erlernt hat.




Figure 4. Composite faces and the average facial landmarks built by averaging faces classified as most and least likely to be gay.

Quelle: Wang & Kosinski *J. Pers. Soc. Psychol.* (2017).

Siehe auch: Calling Bull, [Machine learning about sexual orientation?](#).

Zusammenfassung

- Mit überwachtem Lernen können wir einen Algorithmus darauf trainieren, **bekannte Muster wiederzuerkennen**.
- Es gibt **unterschiedliche Algorithmen** für überwachtes Lernen wie Naive Bayes oder Entscheidungsbäume.
- Die **Performance** von Algorithmen des überwachten Lernens messen wir mit Genauigkeit bzw. F_1 Wert (Klassifikation) und der mittleren quadrierten Abweichung (Regression).
- Die Performance hängt stark von den Trainingsdaten ab. Fehlende Daten und Verzerrungen können Probleme darstellen und zu **Bias** (underfitting) und **Varianz** (overfitting) in den Ergebnissen führen.

Ausblick nächste Vorlesung

Am 8.10. von 15:00 bis 16:45 im HS 10.11.

- **Unüberwachtes Lernen:** wenn wir die Ausgabewerte nicht kennen und uns in großen Datensätzen orientieren müssen.
- **Dimensionsreduktion:** wenn wir einfach zu viele Attribute in unserem Datensatz haben.
- **Verstärkendes Lernen:** wenn wir uns in einer komplexen Umgebung zurechtfinden müssen.