

WiSe 2024/25

KÜNSTLICHE INTELLIGENZ UND GESELLSCHAFT

Vorlesung 3: Maße für Distanz und Ähnlichkeit

Jana Lasser

Forschungsgruppe

Complex Social & Computational Systems (CS)²

IDEa_lab


Das Interdisziplinäre Digitale
Labor der Universität Graz




Wie definieren wir den "Abstand"?

Euklidische Distanz ist ein intuitives *Maß* für Abstand.

Je größer die Distanz,
desto **unähnlicher** sind
sich zwei Datenpunkte.




Euklidische Distanz in 2 Dimensionen



Bauernhof	Milchmenge	Auslauf
q	112	360
p	55	100

Euklidische Distanz in 2 Dimensionen



Bauernhof	Milchmenge	Auslauf
q	112	360
p	55	100

Euklidische Distanz in n Dimensionen

Wenn Datenpunkte mehr als drei Charakteristika haben, ist eine intuitive Visualisierung schwer. Beispiel euklidische Distanz mit 4 Dimensionen:

Bauernhof	Milchmenge [L]	Auslauf [min]	Seehöhe [m]	Größe [# Kühe]
q	112	360	340	1200
p	55	100	600	350


Die euklidische Distanz zwischen zwei Punkten $d(p, q)$ kann auf beliebig viele (n) Dimensionen generalisiert werden:

$$d(p, q) = \sqrt{(q_1 - p_1)^2 + (q_2 - p_2)^2 + \dots + (q_n - p_n)^2}$$

$$d(p, q) = \sqrt{\sum_{i=1}^n (q_i - p_i)^2}$$

Kosinus-Ähnlichkeit

Für Beobachtungen mit vielen numerischen Attributen (Zahlen) bietet sich die Kosinus-Ähnlichkeit an. Warum? → siehe "Fluch der Dimensionalität" später in der VL!




$$S_C(\vec{a}, \vec{b}) := \cos(\theta) = \frac{\vec{a} \cdot \vec{b}}{||\vec{a}|| \cdot ||\vec{b}||} = \frac{\sum_{i=1}^n a_i b_i}{\sqrt{\sum_{i=1}^n a_i^2} \cdot \sqrt{\sum_{i=1}^n b_i^2}}$$

Kosinus-Ähnlichkeit

Quelle: inspiriert von LearnDatasci, [Cosine Similarity](#).

Kosinus-Ähnlichkeit

Für Beobachtungen mit vielen numerischen Attributen (Zahlen) bietet sich die Kosinus-Ähnlichkeit an. Warum? → siehe "Fluch der Dimensionalität" später in der VL!



Bauernhof	Milchmenge x	Auslauf y
a	100	20
b	90	80

$$\vec{a} = \begin{pmatrix} 100 \\ 20 \end{pmatrix} \quad \vec{b} = \begin{pmatrix} 90 \\ 80 \end{pmatrix}$$

$$S_C(\vec{a}, \vec{b}) = \frac{\sum_{i=1}^n a_i b_i}{\sqrt{\sum_{i=1}^n a_i^2} \cdot \sqrt{\sum_{i=1}^n b_i^2}}$$

$$= \frac{100 \cdot 90 + 20 \cdot 80}{\sqrt{100^2 + 20^2} \cdot \sqrt{90^2 + 80^2}} = \frac{10600}{102.98 \cdot 120.42} = 0.86$$

Quelle: inspiriert von LearnDatasci, [Cosine Similarity](#).

Ähnlichkeitsmaße für binäre Attribute

B \ A	0	1
0	Wert 0 bei A und B	Wert 1 bei A, 0 bei B
1	Wert 0 bei A, 1 bei B	Wert 0 bei A, 1 bei B

	Bauernhof	Heu	Melkmaschine
A		1	1
B		1	0

B \ A	0	1
0	M_{00}	M_{10}
1	M_{01}	M_{11}

Jaccard-Ähnlichkeit

$$J = \frac{M_{11}}{M_{01} + M_{10} + M_{11}}$$

Jaccard-Distanz

$$d_J = \frac{M_{01} + M_{10}}{M_{01} + M_{10} + M_{11}} = 1 - J$$

Erinnerung: one-hot encoding für Klassen

Um Attribute mit mehr als zwei Klassen in Wahrheitswerte umzuwandeln, können wir sie one-hot encoden und dann Ähnlichkeitsmaße für Wahrheitswerte verwenden.

Hof	Rasse
a	Holstein
b	Braunvieh
c	Holstein
d	Pinzgauer
e	Braunvieh

One-hot encoding

Hof	Holstein	Braunvieh	Pinzgauer
a	1	0	0
b	0	1	0
c	1	0	0
d	0	0	1
e	0	1	0

Weitere Distanzmaße

Zahlen

- Korrelationskoeffizient
- Manhattan Distanz

Wahrheitswerte

- M-Koeffizient
- Russel & Rao-Koeffizient

Siehe K. Backhaus et al., [Multivariate Analysemethoden](#), Seiten 438-453 für Details.

Zusammenfassung

- Um Clusteranalyse anwenden zu können, müssen wir ein Maß für die **Distanz** bzw. **Ähnlichkeit** von Beobachtungen zueinander etablieren.
- Distanzmaße für Zahlen
 - Euklidische Distanz
 - Kosinus-Ähnlichkeit
- Distanzmaße für binäre Attribute
 - Jaccard-Ähnlichkeit
 - Jaccard-Distanz