

WiSe 2024/25

KÜNSTLICHE INTELLIGENZ UND GESELLSCHAFT

Vorlesung 3: Merkmalskonstruktion (feature engineering) & Dimensionsreduktion

Jana Lasser

Forschungsgruppe
Complex Social & Computational Systems (CS)²

IDEa_lab

Das Interdisziplinäre Digitale
Labor der Universität Graz



Motivation

- Wir haben schon ein **Beispiel für Merkmalkonstruktion** (feature engineering) zur Transformation von Daten gesehen: one-hot encoding.
- Wir können noch einiges mehr tun, um mehr aus Daten "herauszuholen".
- Auf der anderen Seite können Daten auch zu **viele Attribute** / Merkmale / Features haben.
- Die Anzahl der Attribute auf ein sinnvolles Maß zu reduzieren heißt **Dimensionsreduktion**.

Feature Engineering

Beispiel: Recruiter

- Wir arbeiten bei einem Recruiter und möchten herausfinden, auf welche Kandidat:innen wir unsere Bemühungen konzentrieren sollen.
- Wir benutzen Informationen zu Demographie, Einkommen und Abschluss um die Vermittelbarkeit vorherzusagen.

ALTER	EINKOMMEN	GESCHLECHT	TEL. NR.	ABSCHLUSS	VERMITTELT
23	38.000	männlich	+43 664 1467812	Bachelor	ja
35	52.000	weiblich	+49 176 0378193	Master	ja
42	93.000	weiblich	+43 676 5672899	Doktor	ja
31	39.000	männlich	+43 690 8848782		nein
54	84.000	divers	+49 170 2340055	Master	ja
48	45.000	männlich	+43 664 1919822	Bachelor	nein

One-hot encoding und binäre Attribute

- Wir transformieren Wahrheitswerte in Einsen und Nullen.
- Wir verwenden one-hot encoding, um kategoriale Attribute in mehrere Spalten mit binären Attributen aufzutrennen.

ABSCHL_KEIN	ABSCHL_BACH	ABSCHL_MAST	ABSCHL_DR	VERMITTELT
0	1	0	0	1
0	0	1	0	1
0	0	0	1	1
1	0	0	0	0
0	0	1	0	1
0	1	0	0	0

Reskalierung

- Zahlen mit unterschiedlichen Größenordnungen, wie z.B. Alter (zwischen 0 und 100) und Jahreseinkommen (zwischen 0 und 100.000) können ein Problem sein.
- Unterschiedliche **Skalierungen** können dazu führen, dass große Zahlen mehr Gewicht bekommen als kleine, obwohl das nicht beabsichtigt ist.
- Wir **reskalieren** beide Zahlen indem wir durch den maximal möglichen Wert teilen.

ALTER	EINKOMMEN	GESCHLECHT	TEL. NR.	ABSCHLUSS
0.23	0.38	männlich	+43 664 1467812	Bachelor
0.35	0.52	weiblich	+49 176 0378193	Master
0.42	0.93	weiblich	+43 676 5672899	Doktor
0.31	0.39	männlich	+43 690 8848782	
0.54	0.84	divers	+49 170 2340055	Master
0.48	0.45	männlich	+43 664 1919822	Bachelor

Löschen von Attributen

- Manche Attribute sind **geschützt** und dürfen nicht zur Vorhersage von z.B. Beschäftigungsfähigkeit verwendet werden.
- Geschlecht zählt zu diesen Attributen - wir entfernen es.

Rechtliche
Aspekte der KI

Ethische Aspekte
der KI

ALTER	EINKOMMEN		TEL. NR.	ABSCHLUSS
0.23	0.38		+43 664 1467812	Bachelor
0.35	0.52		+49 176 0378193	Master
0.42	0.93		+43 676 5672899	Doktor
0.31	0.39		+43 690 8848782	
0.54	0.84		+49 170 2340055	Master
0.48	0.45		+43 664 1919822	Bachelor

Neue Attribute

- Daraus, wie viel Jahreseinkommen pro Alter eine Person verdient lassen sich vielleicht Rückschlüsse über die Ambitionen der Person ziehen.
- Wir **konstruieren ein neues Attribut** Einkommen / Alter.
- Die Telefonnummern sind nutzlos, da sie zufällig vergeben werden. Aber aus der Vorwahl können wir Rückschlüsse über das Aufenthaltsland ziehen.

ALTER	EINKOMMEN	EINK ALTER	LAND	ABSCHLUSS
0.23	0.38	1.65	Österreich	Bachelor
0.35	0.52	1.49	Deutschland	Master
0.42	0.93	2.21	Österreich	Doktor
0.31	0.39	1.26	Österreich	
0.54	0.84	1.56	Deutschland	Master
0.48	0.45	0.94	Österreich	Bachelor

Dimensionsreduktion

Wenn wir zu viele Attribute haben ...

Problem 1: Große Datenmengen

Erinnern wir uns an das Beispiel mit dem Text:


- Die Deutsche Sprache hat etwa 75.000 Worte.
- Um einen Satz mit 6 Worten darzustellen, brauchen wir eine 75.000 x 6 Zellen große Tabelle.
- Diese würde $75.000 \times 6 \times 32 / 8 / 1024 / 1024 = 1.7$ Megabyte an Speicher belegen* → sehr ineffizient.

	Ich	gehe	mit	dem	Hund	raus
ich	1	0	0	0	0	0
gehe	0	1	0	0	0	0
mit	0	0	1	0	0	0
dem	0	0	0	1	0	0
Hund	0	0	0	0	1	0
raus	0	0	0	0	0	1
Katze	0	0	0	0	0	0
Haus	0	0	0	0	0	0
	...	...	...	...	...	...
du	0	0	0	0	0	0

* Selbst wenn wir die Zahlen nicht als 32 Bit Integer sondern nur als 2 Bit Wahrheitswerte speichern, sind es noch 0.11 MB!

Der Fluch der Dimensionalität

- Fügen wir unserem Datensatz ein weiteres Attribut hinzu, dann bekommt der **Raum** in dem sich unsere Daten befinden eine weitere Dimension.
- Mit jeder weiteren Dimension steigt das **Volumen** des Raumes rapide an.
- **Konsequenz 1:** 100 Stichproben decken den (eindimensionalen) Raum zwischen 0 und 1 gut ab. In einem 10-dimensionalen Raum sind sie viel zu wenig.
- **Konsequenz 2:** Der Unterschied zwischen der kleinsten und der größten **Distanz** zwischen zwei Datenpunkten wird beliebig klein. **Cluster zu finden wird schwierig!**




Ein Zentimeter besteht aus 10 Millimetern, ein Quadratzentimeter hingegen aus 100 Quadratmillimetern.
Quelle: [Wikipedia](#), CC BY-SA 3.0.

→ **Distanzmaße** wie die Euklidische Distanz eignen sich schlecht für hochdimensionale Räume.
Besser: **Ähnlichkeitsmaße** (Kosinusähnlichkeit).

Lösung: Dimensionsreduktion



- **Selektion von Attributen:** Attribute die nichts zur Lösung des Problems beitragen entfernen.
- **Projektion:** Wir suchen nach einer Projektion der Datenpunkte in einen Raum, in dem Unterschiede der Datenpunkte maximal zur Geltung kommen.
- Ein Verfahren mit dem das erreicht werden kann ist die **Hauptkomponentenanalyse** (principal component analysis, PCA).
- Das Ergebnis einer PCA ist eine Projektion der Daten in einen Raum in dem die **Varianz der Datenpunkte in wenigen Dimensionen konzentriert** ist.




Visualisierung einer Projektion mit PCA in zwei Dimensionen. Quelle: [Wikipedia](#), CC BY-SA 4.0.

→ Das Ergebnis der PCA hat zwar erst einmal gleich viele Dimensionen wie der Ausgangsraum aber nur wenige sind wirklich wichtig. **Die anderen Dimensionen können wir entfernen.**

Beispiel PCA für Bauernhöfe



Beispiel PCA für Bauernhöfe



Zusammenfassung

- **Feature Engineering** hilft uns dabei, das meiste aus unseren Daten herauszuholen und Probleme mit den machine learning Algorithmen bzw. rechtlichen Vorgaben zu vermeiden. Techniken sind:
 - One-hot encoding
 - Reskalierung
 - Konstruktion von neuen Attributen
 - Löschen von Attributen
- Zu viele Attribute (Dimensionen) führen zu Problemen beim **Speicherbedarf** und potentiell auch Rechenzeit.
- Der **Fluch der Dimensionalität** sorgt dafür, dass Distanzmaße Bedeutung verlieren und Cluster schwer zu finden sind.
- **Dimensionsreduktion** ist eine Lösung. Sie konzentriert die in den Daten enthaltene Varianz in wenigen Dimensionen.