

WiSe 2024/25

KÜNSTLICHE INTELLIGENZ UND GESELLSCHAFT

Vorlesung 3: Algorithmen für unüberwachtes Lernen

Jana Lasser




Forschungsgruppe
Complex Social & Computational Systems (CS)²

IDEa_Lab

Das Interdisziplinäre Digitale
Labor der Universität Graz




Wie Cluster gebildet werden sollen kann mehrdeutig sein.



Quelle: inspiriert von M. Hahsler, "[Cluster Analysis: Basic Concepts and Algorithms](#)".


Unterschiedliche Clustering-Eigenschaften




Unterschiedliche Clustering-Verfahren führen zu Clustern mit unterschiedlichen Eigenschaften.

Hierarchische Clustering-Verfahren

Algorithmus: *In jedem Schritt verbinde die beiden Cluster mit der größten Ähnlichkeit.*




verschachtelte
Cluster




Dendrogram

Hierarchische Clustering-Verfahren

Algorithmus: *In jedem Schritt verbinde die beiden Cluster mit der größten Ähnlichkeit.*



finales Clustering wenn
Clusteranzahl = 2 gewählt





Dendrogram

Partitionierende Clustering-Verfahren

*Ausgehend von einem gegebenen Clustering, verlagere Datenpunkte in andere Cluster um ein **besseres** Clustering zu finden.*


Zielfunktionen: Intuition

*Um das **beste Clustering** zu finden, optimieren wir eine **Zielfunktion**.
Beispiel: "**Fehlersumme**".*




Zielfunktionen: Intuition

Um das *beste Clustering* zu finden, optimieren wir eine *Zielfunktion*.
Beispiel: "Fehlersumme".



Zielfunktionen: Intuition

Um das *beste Clustering* zu finden, optimieren wir eine *Zielfunktion*.
Beispiel: "*Fehlersumme*".



Fehlerquadratsumme in Cluster C_i berechnen

Die Fehlerquadratsumme wird auch als "Sum of Squared Errors" (SSE) bezeichnet.

Summe über alle Datenpunkte J in Cluster C_i Wert des Attributs k bei Datenpunkt j in Cluster i .

$$SSE_{C_i} = \sum_{j=1}^{J_{C_i}} \sum_{k=1}^K (x_{ijk} - \bar{x}_{ik})^2$$

Summe über alle Attribute K Mittelwert von Attribut k in Cluster i

Fehlerquadratsumme über das Clustering

Die Fehlerquadratsumme wird auch als "Sum of Squared Errors" (SSE) bezeichnet.

Summe über alle Datenpunkte J in Cluster C_i Wert von Attribut k bei Datenpunkt j in Cluster i .

$$SSE = \sum_{i=1}^N \sum_{j=1}^{J_{C_i}} \sum_{k=1}^K (x_{ijk} - \bar{x}_{ik})^2$$

Summe über alle Cluster N Summe über alle Attribute K Mittelwert von Attribut k in Cluster i

K-means:


ein Algorithmus zum finden von Clustern

Intuition: Ausgehend von einem gegebenen Clustering, verlagere Datenpunkte in andere Cluster um die Fehlerquadratsumme (SSE) zu reduzieren.

K-means Algorithmus


1. Gib ein Clustering vor.
2. Berechne den Mittelwert je Eigenschaft & Cluster.
3. Berechne SSE über das gesamte Clustering.
4. Für alle Datenpunkte: überprüfe ob durch Veränderung der Cluster-Zugehörigkeit SSE verringert werden kann.
5. Verschiebe den Datenpunkt mit maximaler Fehlerreduktion in den entsprechenden Cluster.
6. Berechne neue Mittelwerte aller Eigenschaften für den empfangenden und abgebenden Cluster.

Wiederhole Schritte 4. – 6. bis sich keine Reduktion der Fehlerquadratsumme SSE mehr ergibt.



Quelle: Wikipedia, [K-means convergence](#), CC BY-SA 4.0.

Einfluss vom Ausgangs-Clustering




→ Wiederhole das Clustering-Verfahren mehrmals mit unterschiedlichen Ausgangs-Clusterings.

Was ist die optimale Anzahl von Clustern?

Silhouettenkoeffizient: misst, wie ähnlich eine Beobachtung anderen Beobachtungen im selben Cluster ist (Kohäsion) verglichen mit Beobachtungen in anderen Clustern (Separierung). Dabei ist **1 sehr gut** und **-1 sehr schlecht**.


- a_i : mittlere Distanz der Beobachtung i zu allen anderen Beobachtungen im selben Cluster.
- b_i : mittlere Distanz zum nächsten anderen Cluster.
- Der Silhouettenkoeffizient ist der Mittelwert von a_i und b_i über alle Beobachtungen.



Einschränkungen von K-Means Clustering

K-means führt zu unintuitiven Ergebnissen wenn die Cluster ...

- ... unterschiedlich groß sind.
- ... unterschiedlich dicht sind.
- ... keine konvexe Hülle haben.



→ Dichte-basiertes Clustering

Zusammenfassung

- Clusterings können **unterschiedliche Eigenschaften** haben.
 - exklusiv vs. nicht exklusiv
 - komplett vs. partiell
 - dichte-basiert vs. distanzbasiert
- Unterschiedliche Clusteringverfahren produzieren unterschiedliche Clusterings
 - Hierarchische Verfahren
 - Partitionierende Verfahren (k-Means)