

KÜNSTLICHE INTELLIGENZ UND GESELLSCHAFT

Vorlesung 3: Zusammenfassung unüberwachtes Lernen

Jana Lasser

Forschungsgruppe
Complex Social & Computational Systems (CS)²



IDEa_lab

Das Interdisziplinäre Digitale
Labor der Universität Graz



Astronomie: Detektion von Galaxienhaufen


- **Frage:** Was ist die intrinsische Struktur von Galaxienhaufen?
- **Herangehensweise:**
 - Gruppierung von Galaxien in Galaxienhaufen in einer gegebenen Himmelsregion mit einem hierarchischen Clustering-Algorithmus.
 - Spezielle **Distanzmetrik** (Bindungsenergie) die Verbindungen zwischen Galaxien beschreibt.
- **Resultat:** Hierarchische Struktur (Dendogramm) der Galaxienhaufen.



Galaxiehaufen die in der Himmelsregion nahe Supercluster A2029 entdeckt wurden. Quelle: Yu & Hou, [Hierarchical clusterin in astronomy](#), *Astronomy and Computing* (2022).

Soziologie: Probleme junger Mütter



- **Frage:** Welche Themen beschäftigen junge Mütter besonders?
- **Herangehensweise:**
 - Identifikation von relevanten öffentlichen Gruppen auf Facebook mit Hilfe von Schlagworten und Expert:innen.
 - Sammeln von 840.000 Posts.
 - Identifikation von Themen mittels Textkategorisierung (Topic Modelling).
- **Resultat:** Klar abgegrenzte und interpretierbare Themen.
- **Nutzung:** vom *Verein zur Förderung von Kinderschutz und Kindergesundheit in Österreich* zur Entwicklung einer neuen Informationsbroschüre.



Themen, die von Jungen Müttern auf Facebook diskutiert werden.
Projektarbeit von Magdalena Fritz.

Biologie: Charakteristika von Pflanzenblättern

- **Frage:** Können wir Informationen aus den Transportnetzwerken von Pflanzenblättern verwenden, um verschiedene Spezies zu unterscheiden?
- **Herangehensweise:**
 - Extraktion von Transportnetzwerken und Messung von Charakteristika der Netzwerke (Topologie) und geometrischen Charakteristika.
 - Clustering von Pflanzenblättern anhand der Charakteristika & Dimensionsreduktion.
- **Resultate:**
 - Die Netzwerkstruktur enthält Informationen die in der geometrischen Struktur nicht enthalten sind.
 - Die PCA zeigt deutlich, dass Geometrie und Topologie unterschiedliche Dimensionen abdecken.



Quelle: Ronellenfitsch et al., [Topological Phenotypes Constitute a New Dimension in the Phenotypic Space of Leaf Venation Networks](#), *PLoS Comp. Biol.* (2015).

Zusammenfassung

- Mit Clusteranalyse bzw. unüberwachtem Lernen können wir **unbekannte Muster in Daten entdecken** und ähnliche Beobachtungen in Gruppen **zusammenfassen**.
- Um Ähnlichkeiten zwischen Beobachtungen zu charakterisieren, brauchen wir ein **Distanzmaß** wie z.B. die euklidische Distanz oder die Kosinus-Ähnlichkeit.
- Haben unsere Daten zu viele Attribute ist es sinnvoll, **Dimensionsreduktion** wie z.B. Hauptkomponentenanalyse (PCA) anzuwenden, um die Attribute auf das Wesentliche zu reduzieren.
- Es gibt **unterschiedliche Algorithmen** für unüberwachtes Lernen wie z.B. hierarchisches Clustering, K-means und dichte-basiertes Clustering.