

WiSe 2024/25

KÜNSTLICHE INTELLIGENZ UND GESELLSCHAFT

Vorlesung 4: Text als Daten

Jana Lasser

Forschungsgruppe
Complex Social & Computational Systems (CS)²

IDEa_lab

Das Interdisziplinäre Digitale
Labor der Universität Graz



Rückblick Vorlesung 3

- **Frage:** *Wie funktioniert unüberwachtes lernen und was unterscheidet es von überwachtem Lernen?*
- **Frage:** *Warum sind Distanz- bzw. Ähnlichkeitsmaße wichtig für unüberwachtes Lernen?*
- **Frage:** *Wie funktioniert der k-Means Algorithmus?*

Überblick über die heutige Vorlesung

- Text als Daten
- Vorhersage von Sequenzen
- Große Sprachmodelle
- Empfehlungssysteme
- Das Empfehlungssystem von X
- Zusammenfassung technische Grundlagen der KI

Paper [word2vec Parameter Learning Explained](#)

Video [CS 198-126: Lecture 14 - Transformers and Attention](#)

Paper [Language Models are Few-Shot Learners](#)

Vorlesungsfolien [Recommender Systems: Value, Methods, Measurements](#)

Blog Post [Twitter's Recommendation Algorithm](#)

[Weiterführende Lektüre]

Lernziele

- Verstehen wie große Sprachmodelle aufgebaut sind und warum sie Halluzinieren und Fehler machen.
- Verstehen wie Empfehlungssysteme aufgebaut sind und warum sie zu Problemen führen können.

Text in Zahlen umwandeln

- Die Deutsche Sprache hat ~75.000 Worte.
- Text als one-hot codierte Vektoren darzustellen ist extrem ineffizient.
- Wie können wir die Codierung effizienter machen?
- **Lösung:** erlernte "Einbettungen".

	1	2	3	4	5	6	7	8
Katze	1	0	0	0	0	0	0	0
Kätzchen	0	1	0	0	0	0	0	0
Hund	0	0	1	0	0	0	0	0
Häuser	0	0	0	1	0	0	0	0
Mann	0	0	0	0	1	0	0	0
Frau	0	0	0	0	0	1	0	0
König	0	0	0	0	0	0	1	0
Königin	0	0	0	0	0	0	0	1

one-hot Codierung

Jedes Wort wird von einem Vektor mit 8 Einträgen repräsentiert.

Text in Zahlen umwandeln

- Die Deutsche Sprache hat ~75.000 Worte.
- Text als one-hot codierte Vektoren darzustellen ist extrem ineffizient.
- Wie können wir die Codierung effizienter machen?
- **Lösung:** erlernte "Einbettungen".


	Lebewesen	katzenartig	Mensch	Geschlecht	königlich	Verb	Plural
Katze	0.6	0.9	0.1	0.4	-0.7	-0.3	-0.2
Kätzchen	0.5	0.8	-0.1	0.2	-0.6	-0.5	-0.1
Hund	0.7	-0.1	0.4	0.3	-0.4	-0.1	-0.3
Häuser	-0.8	-0.4	-0.5	0.1	-0.9	0.3	0.8
Mann	0.6	-0.2	0.8	0.9	-0.1	-0.9	-0.7
Frau	0.7	0.3	0.9	-0.7	0.1	-0.5	-0.4
König	0.5	-0.4	0.7	0.8	0.9	-0.7	-0.6
Königin	0.8	-0.1	0.8	-0.9	0.8	-0.5	-0.9

Wort Einbettung

*Jedes Wort wird von einem Vektor mit **7 Einträgen** repräsentiert.*


Adaptiert von
Word embedding: basics"
Hariom Gautam @Medium.

Einbettungen lernen



Inspiziert von Manan Suri, [A Dummy's Guide to Word2Vec](#), Medium.

Einbettungen lernen



Inspiziert von Manan Suri, [A Dummy's Guide to Word2Vec](#), Medium.


Vorteile von Einbettungen

- Wir benötigen viel weniger Dimensionen (üblicherweise zwischen 100 und 1000) um ein Wort darzustellen.
- Worte, die einander ähnlich sind, befinden sich an ähnlichen Positionen im *Einbettungsraum*. Die **Kosinus-Ähnlichkeit** ihrer Einbettungsvektoren ist sehr hoch.

$$S_C(\vec{a}, \vec{b}) := \cos(\theta) = \frac{\vec{a} \cdot \vec{b}}{||\vec{a}|| ||\vec{b}||} = \frac{\sum_{i=1}^n a_i b_i}{\sqrt{\sum_{i=1}^n a_i^2} \cdot \sqrt{\sum_{i=1}^n b_i^2}}$$


Kosinus-Ähnlichkeit

- Wir können mit Einbettungsvektoren "rechnen".



Mit Einbettungen rechnen

"Mann" verhält sich
im Vektorraum zu
"Frau" wie "Bruder"
zu "Schwester".



Zusammenfassung

- Um Text als Daten für maschinelles Lernen verwenden zu können, müssen wir ihn erst in Zahlen umwandeln.
- Dies geschieht mittels **Einbettungen** - Vektoren mit 100 bis 1000 Dimensionen die ein Wort im Kontext seiner Sprache darstellen.
- Einbettungen werden mit Hilfe von neuronalen Netzen und großen Mengen von natürlich vorkommendem Text erlernt.
- Die Einbettungsvektoren von Worten die eine ähnliche Bedeutung haben, weisen eine hohe Kosinus-Ähnlichkeit auf - die Worte befinden sich an ähnlichen Orten im Einbettungsraum.