

WiSe 2024/25

KÜNSTLICHE INTELLIGENZ UND GESELLSCHAFT

Vorlesung 4: Vorhersage von Sequenzen

Jana Lasser

Forschungsgruppe

Complex Social & Computational Systems (CS)²

IDEa_lab

Das Interdisziplinäre Digitale
Labor der Universität Graz



Überwachtes Lernen zur Generierung von Sequenzen

- Beim überwachten Lernen wird ein Zusammenhang zwischen Werten von Attributen von Beobachtungen und gewünschten Ausgabewerten (Klassen, Zahlen) erlernt, um **Ausgabewerte für unbekannte Beobachtungen vorherzusagen**.
- Die **Generierung von Sequenzen** funktioniert ähnlich: gegeben eine existierende Sequenz (Beobachtung) mit ihren Attributen (existierende Glieder der Sequenz), sage das nächste Glied der Sequenz voraus (Ausgabewert).
- Bei der Vorhersage des darauf folgenden Gliedes wird das zuletzt vorhergesagte Glied der Sequenz als Attributswert der Beobachtung mit betrachtet.

Anwendung: Generierung von Wortsequenzen

Ziel: gegeben eine Sequenz von Worten, sage das nächste Wort voraus.

Ich hatte noch keinen Kaffee, deswegen bin ich ...

wütend
müde
gelb

Exkurs: bedingte Wahrscheinlichkeiten

$$P(\text{Regen}) = 0.5$$

$$P(\text{Regen} \mid \text{Wetterbericht}) = 0.8$$

$$P(\text{Regen} \mid \text{Wetterbericht}, \text{Wolken}) = 0.9$$

Die Zusammenhänge zwischen Sequenzen und Wahrscheinlichkeiten für das nächste Wort werden anhand von riesigen Textmengen gelernt.

$$P(\text{wütend} \mid \text{ich, hatte, noch, keinen, ...}) = 0.001$$

$$P(\text{müde} \mid \text{ich, hatte, noch, keinen, ...}) = 0.01 \quad \text{"Kontext"}$$

$$P(\text{gelb} \mid \text{ich, hatte, noch, keinen, ...}) = 0.0001$$

Wenn $P(\text{müde})$ größer als alle anderen Wahrscheinlichkeiten, dann sag "müde" voraus.

Kodierer – Dekodierer Architektur

Aufgabe


Gegeben eine Sequenz von Worten, sage das nächste Wort voraus.

Anwendungsbeispiele

- Übersetzung
- Textgenerierung

Herausforderungen

- sequentielle Berechnung
- limitierte Kontextlänge



Traditionelle Encoder-Decoder Architektur zur Übersetzung.
Quelle: Adaptiert von [CS 198-126: Lecture 14 - Transformers and Attention](#)


Kodierer – Dekodierer mit "Aufmerksamkeit"

Aufmerksamkeit (attention)

Lerne die Wichtigkeit jedes Wortes im Kontext über Gewichte w_i .

Vorteile

- parallele Berechnung
- unendliche Kontextlänge



Traditionelle Encoder-Decoder Architektur zur Übersetzung.
Quelle: Adaptiert von [CS 198-126: Lecture 14 - Transformers and Attention](#)

Intuition für "Aufmerksamkeit"

Aufgabe: Gegeben eine Sequenz von Worten, generiere das nächste Wort.

Eingabesequenz Ausgabesequenz

This morning, I had no coffee. The realization

x_1 x_2 $x_3 x_4$ x_5 x_6 x_7 x_8 y_1 y_2


Eingabe-Einbettungen Ausgabe-Einbettungen

Einbettung: Repräsentation eines Wortes als Vektor.

Intuition für "Aufmerksamkeit"

Aufgabe: Gegeben eine Sequenz von Worten, generiere das nächste Wort.


This morning, I had no coffee. The realization

A diagram illustrating attention weights. The text "This morning, I had no coffee. The realization" is shown. The words "The" and "realization" are highlighted in red. Two curved arrows originate from the red text and point back to the word "no" in the preceding clause, indicating that the model is attending to the context of the previous sentence to generate the next word.

Während der Text generiert wird, wird unterschiedlichen Teilen der Eingabe **Aufmerksamkeit** geschenkt.

Intuition für "Aufmerksamkeit"


Aufgabe: Gegeben eine Sequenz von Worten, generiere das nächste Wort.



Welches Wort in der Eingabe wie viel Aufmerksamkeit bekommt wird während des Trainings **erlernt**.

Intuition für "Aufmerksamkeit"


Aufgabe: Gegeben eine Sequenz von Worten, generiere das nächste Wort.



Dieses Vorgehen ermöglicht Interaktionen über lange Textteile hinweg.

"Transformer" – Architektur von ChatGPT

Abbildung adaptiert von Vaswani et al.
[Attention is all you need](#) (2017).



Zusammenfassung

- Die Generierung von Sequenzen funktioniert nach dem Prinzip des überwachten Lernens:
 - Vorangegangene Glieder der Sequenz dienen als Attributswerte der Beobachtung.
 - Das nächste Glied wird vorhergesagt und dann der Beobachtung hinzugefügt.
 - Zusammenhänge zwischen Sequenzen und dem nächsten wahrscheinlichen Glied werden gelernt.
- Beim Einsatz von **Aufmerksamkeit** (attention) wird zusätzlich noch erlernt, wie wichtig ein vorangegangenes Glied ist. Das ermöglicht sehr weit zurückreichende Interaktionen zwischen Eingabesequenz und Ausgabewert.
- Die Architektur, die Sprachmodellen wie ChatGPT zugrunde liegt heißt "Transformer" – ein Kodierer und Dekodierer mit Aufmerksamkeit.