

WiSe 2024/25

# KÜNSTLICHE INTELLIGENZ UND GESELLSCHAFT

## Vorlesung 4: große Sprachmodelle

**Jana Lasser**

Forschungsgruppe

Complex Social & Computational Systems (CS)<sup>2</sup>

**IDEa\_lab**


Das Interdisziplinäre Digitale  
Labor der Universität Graz



# Große Sprachmodelle – large language models (LLMs)

- Große Sprachmodelle die auf Anfrage Text generieren können haben sich seit dem Release von ChatGPT im Jahr 2022 extrem weit verbreitet.
- Um große Sprachmodelle zu trainieren, brauchen wir alle Spielarten von maschinellem Lernen.
- Im Folgenden folgen wir Schritt für Schritt dem Prozess des Trainings eines großen generativen Sprachmodells.

# Schritt 1: Vortraining mit semi-überwachtem Lernen



Trainingskorpus von GPT-3 beinhaltet:

- **CommonCrawl** (400 Mrd Tokens, 46% English) – niedrige Qualität.
- Reddit (19 Mrd Tokens), Wikipedia (3 Mrd Tokens) – hohe Qualität.
- Bücher (67 Mrd Tokens) – hohe Qualität.

Siehe auch Brown et al., [Language Models are Few-Shot Learners](#), *arXiv* (2020).

Kosten GPT-4: \$100 mio

**Wirtschaftliche  
Aspekte der KI**

# Vortrainiertes Sprachmodell


- Ein auf diese Weise vortrainiertes Sprachmodell kann bereits sehr gut **kohärente Sequenzen von Worten** produzieren.
- Es "spricht" die Sprachen, die genügend häufig im Trainingsdatensatz enthalten sind und hat Strukturen von Grammatik erlernt.
- Vortrainierte Sprachmodelle sind **sehr groß**: es handelt sich um neuronale Netze mit etwa 80 Mrd. Parametern (Gewichten). Das entspricht etwa 45 GB Festplattenspeicher nur für das Speichern der Modellgewichte.
- Das Modell kann allerdings noch keinen **Instruktionen folgen**. Produzierter Text folgt eher der Struktur von Büchern oder Artikeln als der von Konversationen.

# Schritt 2: Überwachtes Lernen zum Folgen von Instruktionen

Liste mit Instruktionen  
(Prompts)

*Erkläre mir  
das Schritt  
für Schritt...*

Menschen schreiben  
Text als Reaktion



Trainingsdatensatz

| Prompt         | menschliche<br>Reaktion |
|----------------|-------------------------|
| Erkläre ...    | Als erstes ...          |
| Erzähle ...    | Es war einmal ...       |
| Nenne alle ... | 1. ...<br>2. ...        |

Vorangegangene  
Konversation

+

Prompt




generierte  
Ausgabesequenz


# Instruktions-getunt es Sprachmodell

- Das "fine-tuning" des Modells mit einem kleinen Datensatz von Instruktion-Antwort Paaren verändert die Gewichte des Modells nur oberflächlich – die Grundstruktur der Sprache bleibt erhalten.
- Ein Instruktions-getunt es Sprachmodell kann sinnvoll auf Instruktionen als Eingabesequenz reagieren.
- Es produziert allerdings noch Antworten, die **unfreundlich, gefährlich oder irreführend** sein können.


# Rückblick: bestärkendes Lernen




# Rückblick: bestärkendes Lernen



# Schritt 3: Bestärkendes Lernen mit menschlichem Feedback





- Auch bestärkendes Lernen verändert die Gewichte des Modells nur oberflächlich.
- Darunter liegt immer noch das vortrainierte Modell, dass das "Verhalten" des LLMs beeinflusst.
- Im Vortraining erlernte Textmuster können mit dem richtigen Prompting immer noch **zum Vorschein kommen** – auch wenn sie unerwünscht sind.

# Wo funktionieren LLMs (nicht) gut?

- **Aufgaben die Fehler tolerieren:** Generierung von Geschichten, Automatisierung mancher Textbausteine, ...  
→ LLMs können sehr gut kohärent klingende Texte produzieren.
- **Aufgaben die Faktenwissen oder Logik erfordern:** Mathematik, Suche nach Wissen, Erstellen eines Plans, ...  
→ LLMs haben kein Wissen oder Verständnis. Sie agieren rein probabilistisch.
- **Aufgaben die kritisches Denken erfordern:** Brainstorming, philosophische Debatten, ...  
→ LLMs sind darauf trainiert, hilfreich und harmlos zu sein. Sie geben ungern Widerworte.